

Dobry projekt bazy danych

Aspekty

NULL-e — krotki powinny pasować do schematu tabeli,

Redundancja — informacja nie powinna być zapisywana wielokrotnie,

Kontrola więzów — sprawdzanie własności klucza, unikalności i innych więzów powinno być łatwe,

Obliczanie złączeń — jest trudne, więc nie należy rozdrabniać zbytnio bazy.

OSOBA(ido,tytuł,indeks,nazwisko,adres), GRUPA(idg,idk,idp,termin,limit,sala)

- Student ma indeks i nie ma tytułu; pracownik — odwrotnie:
PR(ido,tytuł,nazwisko,adres), ST(ido,indeks,nazwisko,adres)
- Grupa ma kilka terminów zajęć — kilkakrotne wpisanie grupy do tabeli oznacza redundancję (limit, idk,idp): **GR(idg,idk,idp,limit), TS(idg,termin,sala)**
- Łatwo sprawdzić:
 - grupa ma jednego prowadzącego
 - studenci mają unikalne indeksy
- Trudno sprawdzić, że identyfikatory osób są unikalne.
- Wyznaczenie terminu i sali zajęć grupy wymaga złączenia.

Definicja i przykład

Definition (Zależność funkcyjna)

Dla relacji $R = A_1 A_2 \dots A_k$ oraz zbiorów jej atrybutów $\alpha, \beta \subseteq \{A_1 A_2 \dots A_k\}$ zachodzi zależność funkcyjna $\alpha \rightarrow \beta$, jeżeli dla każdego stanu r relacji R zachodzi:

$$(\forall t_1, t_2 \in r)((t_1.\alpha = t_2.\alpha) \Rightarrow (t_1.\beta = t_2.\beta))$$

W relacjach [PR\(ido, tytuł, nazwisko, adres\)](#), [ST\(ido, indeks, nazwisko, adres\)](#) i [GR\(idg, idk, idp, limit\)](#), [TS\(idg, termin, sala\)](#) zachodzą zależności

- w PR: $ido \rightarrow nazwisko, adres, tytuł$,
- w ST: $ido \rightarrow nazwisko, adres, indeks$ oraz $indeks \rightarrow ido, nazwisko, adres$;
- w GR: $idg \rightarrow idk, idp, limit$
- w TS: $termin, sala \rightarrow idg$

Spostrzeżenie: Jeśli K jest kluczem R , to $K \rightarrow R$.

Klucz relacji

Definition (Klucz relacji)

Kluczem relacji R nazywamy taki podzbiór K jej atrybutów, który:

- wyznacza funkcyjnie wszystkie atrybuty R , czyli $K \rightarrow R$ oraz
- jest minimalnym zbiorem o tej własności, czyli $(\forall L \subsetneq K) \neg (L \rightarrow R)$

Definition

Nadklucz relacji — dowolny zbiór atrybutów zawierający klucz relacji,

Klucz główny — jeden z kluczy relacji,

Klucz alternatywny — klucz relacji inny niż klucz główny,

Atrybut główny — atrybut (dowolnego) klucza relacji.

W relacji **ST(ido,indeks,nazwisko,adres)** w relacji **TS(idg,termin,sala)**

- Kluczem jest *indeks* i kluczem jest *ido*,
- Nadkluczami są: $\{indeks, nazwisko\}$ lub $\{ido, indeks, adres\}$,
- Jako klucz główny możemy wybrać *indeks*,
- Atrybuty główne to $\{ido, indeks\}$
- W relacji TS kluczem jest $\{termin, sala\}$

Reguły dla zależności funkcyjnych

Definition (Aksjomaty Armstronga i in.)

Dla relacji R i zbiorów jej atrybutów $\alpha, \beta, \gamma \subseteq R$ zachodzi:

Zwrotność $(\beta \subseteq \alpha) \Rightarrow (\alpha \rightarrow \beta)$ (zależności trywialne)

Rozszerzanie $(\alpha \rightarrow \beta) \Rightarrow (\alpha\gamma \rightarrow \beta\gamma)$

Przechodniość $(\alpha \rightarrow \beta \wedge \beta \rightarrow \gamma) \Rightarrow (\alpha \rightarrow \gamma)$

Sumowanie $(\alpha \rightarrow \beta \wedge \alpha \rightarrow \gamma) \Rightarrow (\alpha \rightarrow \beta\gamma)$

Rozkładanie $(\alpha \rightarrow \beta\gamma) \Rightarrow (\alpha \rightarrow \beta \wedge \alpha \rightarrow \gamma)$

Definition (Domknięcie zbioru zależności i zbioru atrybutów)

Dla relacji R i jej zbioru zależności funkcyjnych F :

F^+ — **domknięciem zbioru zależności** F nazywamy zbiór wszystkich zależności wyprowadzalnych z F .

$(\alpha)_F^+$ — **domknięciem zbioru atrybutów** $\alpha \subseteq R$ **względem** F nazywamy zbiór atrybutów, które można wyprowadzić z α za pomocą F .

Twierdzenie o znaczeniu Aksjomatów Armstronga

Definition (Aksjomaty Armstronga)

Dla relacji R i zbiorów jej atrybutów $\alpha, \beta, \gamma \subseteq R$ zachodzi:

Zwrotność $(\beta \subseteq \alpha) \Rightarrow (\alpha \rightarrow \beta)$ (zależności trywialne)

Rozszerzanie $(\alpha \rightarrow \beta) \Rightarrow (\alpha\gamma \rightarrow \beta\gamma)$

Przechodność $(\alpha \rightarrow \beta \wedge \beta \rightarrow \gamma) \Rightarrow (\alpha \rightarrow \gamma)$

Theorem

Aksjomaty Armstronga stanowią zupełny, niesprzeczny i minimalny zbiór reguł pozwalający wyprowadzić ze zbioru zależności F każdą zależność funkcyjną prawdziwą w każdym stanie relacji, w którym spełnione są reguły F .

Wniosek

Tym samym zależności **dowodliwe** za pomocą aksjomatów Armstronga to zależności **prawdziwe**.

Uwagi ad. domknięcia zbiorów zależności i atrybutów

- ❶ Zazwyczaj nie wyznaczamy F^+ — to zbiór duży i zawierający dużo nieciekawych informacji (np. zależności trywialne).
- ❷ Efektywne wyznaczanie $(\alpha)_F^+$ jest potrzebne — pozwala zdecydować, co jest kluczem, czy w relacji jest redundancja itp.
- ❸ Mamy algorytm, który pozwala wyznaczać $\chi = (\alpha)_F^+$:
 - $\chi \leftarrow \alpha$ (zwrotność)
 - dopóki χ zmienia się:
 - znajdź $\beta \in \chi$ taki, że istnieje $\gamma \rightarrow \beta \in F$ oraz $\gamma \setminus \chi \neq \emptyset$
 - $\chi \leftarrow \chi \cup \gamma$ (zastosuj rozszerzanie i przechodność)
 - zwróć χ jako wynik
- ❹ Mamy sposób, by porównywać zbiory zależności F i G dla tej samej relacji. Sprawdzamy, czy $F^+ = G^+$:
 - dla każdej zależności $\alpha \rightarrow \beta \in F$:
 - oblicz $\chi = (\alpha)_G^+$
 - jeśli $\beta \subseteq \chi$, to $\alpha \rightarrow \beta \in G^+$, w przeciwnym wypadku $F^+ \neq G^+$
 - powtórz to dla każdej zależności $\alpha \rightarrow \beta \in G$ i zbioru F
- ❺ Zależności funkcyjne powinny być kontrolowane przez SZBD. Dlatego dobrze, by było ich mało. Zbiór F_{min} nazwiemy minimalnym pokryciem F jeśli jest równoważny F i nie zawiera zależności "nadmiarowych".

Postać normalna Boyce-Codda

Definition (Postać normalna Boyce-Codda, BCNF)

Relacja R ze zbiorem zależności funkcyjnych F jest w postaci normalnej Boyce-Codda, jeśli dla każdej nietrywialnej zależności $\alpha \rightarrow \beta$ ($\alpha \cap \beta = \emptyset$) zbiór α jest nadkluczem.

Uwagi:

- 1 Relacja w BCNF ma tylko zależności trywialne i wynikające z nadklucza.
- 2 Kontrola zależności funkcyjnych w relacji w BCNF sprowadza się do kontroli własności klucza.

Przykłady:

- 1 $R = ABCDE$ oraz $F = \{AB \rightarrow C, B \rightarrow D, C \rightarrow E, E \rightarrow C\}$ nie jest w BCNF. Kluczem jest AB . Tylko $AB \rightarrow C$ nie narusza BCNF. Pozostałe:
 - **zależność częściowa:** $B \rightarrow D$ wynika z podzbioru klucza,
 - **zależności przechodnie:** $C \rightarrow E$ i $E \rightarrow C$, których lewa strona nie należy do klucza.
- 2 $R = ABC$ oraz $F = \{AB \rightarrow C\}$ jest w BCNF

Rozkład relacji

- **Rozkładem relacji R** nazywamy zbiór relacji $\{R_1, \dots, R_k\}$ taki, że $R = R_1 \cup \dots \cup R_k$.
- Dla F — zbioru zależności R , **rzutem F na R_i** jest $F_i = \{\alpha \rightarrow \beta \in F^+ \mid \alpha, \beta \in R_i\}$.
- Dla r — stanu relacji R , **stanem R_i** jest $r_i = \pi_{R_i}(r)$.
- **Złączenie naturalne** jest operacją przeciwną do rozkładu.
- Rozkład R na R_1, \dots, R_k jest **odwracalny**, jeśli dla każdego poprawnego stanu r (spełniającego zależności F) zachodzi:

$$r = r_1 \bowtie r_2 \bowtie \dots \bowtie r_k$$

- Rozkład R na R_1, \dots, R_k **zachowuje zależności**, jeśli:

$$F^+ = (F_1 \cup F_2 \cup \dots \cup F_k)^+$$

- **Rozkład relacji na składowe MUSI być odwracalny i POWINIEN zachowywać zależności.**

Rozkład relacji do BCNF

Lemma

Niech R będzie relacją i F jej zbiorem zależności funkcyjnych. Jeżeli $\alpha \rightarrow \beta \in F^+$ jest nietrywialna ($\alpha \cap \beta = \emptyset$), to rozkład R na $R_1 = \alpha\beta$ i $R_2 = R \setminus \beta$ jest odwracalny.

Lemma

Każda relacja ma **odwracalny** rozkład na składowe w BCNF.

Lemma

Istnieją relacje, które nie mają **odwracalnego i zachowującego zależności** rozkładu na składowe w BCNF.

Przykład rozkładu do BCNF

Dane:

- $R = KNGSUO$
- $F = \{K \rightarrow N, KU \rightarrow O, GS \rightarrow K, GU \rightarrow S, NG \rightarrow S\}$
- klucz R to GU

Rozkład:

R: R nie jest w BCNF. Rozkładamy wg $KU \rightarrow O$ na $R_1 = KUO$ i $R_2 = KNGSU$;

R_1 : $R_1 = \underline{KU}O$, $F_1 = \{KU \rightarrow O\}$ (BCNF)

R_2 : $R_2 = KNG\underline{SU}$, $F_2 = \{K \rightarrow N, NG \rightarrow S, GS \rightarrow K, GU \rightarrow S\}$ (Nie-BCNF)

R_{21} : $R_{21} = K\underline{GSU}$, $F_{21} = \{KG \rightarrow S, GS \rightarrow K, GU \rightarrow S\}$. (Nie-BCNF)

R_{211} : $R_{211} = KGS$, $F_{211} = \{KG \rightarrow S, GS \rightarrow K\}$, klucze: KG i GS . (BCNF)

R_{212} : $R_{212} = K\underline{GU}$, $F_{212} = \{GU \rightarrow K\}$. (BCNF)

R_{22} : $R_{22} = \underline{KN}$, $F_{22} = \{K \rightarrow N\}$ (BCNF).

Wynik rozkładu: $R = KUO \cup KGS \cup KGU \cup KN$ i
 $\{KU \rightarrow O, KG \rightarrow S, GS \rightarrow K, GU \rightarrow K, K \rightarrow N\}$

Trzecia postać normalna

Definition (Trzecia postać normalna, 3NF)

Relacja R z zależnościami funkcyjnymi F jest w trzeciej postaci normalnej, jeśli każda zależność $\alpha \rightarrow B \in F$

- jest trywialna ($B \in \alpha$) albo
- wynika z nadklucza ($(\alpha)_F^+ = R$) albo
- ma po prawej stronie atrybut główny (B należy do jakiegoś klucza).

Lemma

Każda relacja ma odwracalny i zachowujący zależności rozkład na składowe w postaci 3NF.

Algorytm rozkładu do 3NF

Definition (F_{min})

Minimalnym pokryciem zbioru zależności funkcyjnych F nazwiemy równoważny F zbiór F_{min} , w którym:

- nie ma zależności trywialnych, np. $AB \rightarrow AC$
- nie ma zależności nadmiarowych, czyli wynikających z pozostałych zależności F_{min} , np. $A \rightarrow B, B \rightarrow C, A \rightarrow C$
- nie ma atrybutów lewostronnie nadmiarowych $AB \rightarrow C, A \rightarrow B$.

Algorytm rozkładu do 3NF

- 1 Wyznacz F_{min} .
- 2 Dla każdej zależności $\alpha \rightarrow \beta \in F_{min}$ utwórz składową $R_i = \alpha\beta$. Usuń składowe zawierające się w innych.
- 3 Jeśli żadna z utworzonych składowych nie zawiera klucza R , to dodaj do rozkładu składową K dla pewnego klucza K relacji R .

Postaci normalne

- 1NF — relacja jest w pierwszej postaci normalnej, jeśli ma atrybuty bez wewnętrznej struktury i bez powtórzeń.
- 2NF — relacja jest w drugiej postaci normalnej, jeśli jest w 1NF i nie ma zależności częściowych (unikamy redundancji).
- 3NF — relacja jest w trzeciej postaci normalnej, jeśli jest w 2NF i nie ma zależności przechodnich (unikamy redundancji).
- 3.5NF — BCNF (unikamy redundancji i upraszczamy sprawdzanie zależności).
- inne — unikalność i do w PR i ST, przestrzeganie limitu w grupie, brak kolizji w salach, podawanie świeżych soków tylko w wyznaczonych barach.

Zależności wielowartościowe i 4NF

Definition (Zależność wielowartościowa)

Mamy:

- relację R ze zbiorem zależności funkcyjnych F
- podzbiory atrybutów $\alpha, \beta \subseteq R$ i $\gamma = R \setminus (\alpha \cup \beta)$,
- r — poprawny stan R .

Wtedy zachodzi zależność wielowartościowa $\alpha \twoheadrightarrow \beta$, o ile

- jeśli mamy $t_1, t_2 \in r$ oraz $t_1.\alpha = t_2.\alpha = a$, to
- do r należą także s_1, s_2 , takie że $s_1 = (a, t_1.\beta, t_2.\gamma)$ oraz $s_2 = (a, t_2.\beta, t_1.\gamma)$

Zależność $\alpha \twoheadrightarrow \beta$ jest **trywialna**, jeśli $\beta \subseteq \alpha$ lub $\gamma \subseteq \alpha$.

Definition (Czwarta postać normalna, 4NF)

Relacja R z zależnościami funkcyjnymi F i wielowartościowymi M jest w czwartej postaci normalnej, jeśli każda nietrywialna zależność $\alpha \twoheadrightarrow \beta \in M$ wynika z nadklucza, tzn. $(\alpha)_F^+ = R$.

Uwaga: Relację R z nietrywialną zależnością $\alpha \twoheadrightarrow \beta$, gdzie $\alpha \cap \beta = \emptyset$ można bezpiecznie (odwracalnie i z zachowaniem zależności) rozłożyć na składowe $R_1 = \alpha\beta$ oraz $R_2 = \alpha \cup (R \setminus \beta)$.